

# Определение местоположения с помощью инерционных датчиков

Макаров М., Зайнулина Э., Киселёва Е., Фатеев Д.,  
Божедомов Н., Толканев А., Ночевкин В., Протасов В.,  
Рябов А.

Московский физико-технический институт

*Курс: Численные методы обучения по прецедентам  
(практика, В. В. Стрижов)/Группа 694, весна 2019*

# Цель работы: повысить точность геопозиционирования

## Задача

Позиционирование телефона в помещениях при условиях, когда глобальная навигационная система не может быть задействована, используя только инерционные датчики и данные о расположении телефона.



## Проблема

Значение инерциальных измерительных модулей (IMU) неточно, поэтому двойное интегрирование сигнала даёт траекторию, значительно отклоняющуюся от истинной.

## Метод решения

Использовать априорные знания о расположении телефона для регрессии векторов скорости.

# Траектория движения носителя телефона



Истинная траектория  
SVM  
CNN

## Базовое решение

Hang Yan, Qi Shan, and Yasutaka Furukawa. Ridi: Robust imu double integration. CoRR, abs/1712.09004, 2017.

## Вычислительные эксперименты

Boyuan Wang, Xuelin Liu, Baoguo Yu, Ruicai Jia, and Xingli Gan. Pedestrian dead reckoning based on motion mode recognition using a smartphone. Sensors, 18(6):1811, 2018.

## Структура данных

$x \in \mathbb{R}^{N \times T}$  — признаки объекта — угловые скорости и линейные ускорения в стабилизированной системе координат датчиков.

Частота снятия данных — 200 Гц

$y \in \mathbb{R}^{2 \times T}$  — траектория пешехода,  $v(t)$  — скорость пешехода,  $p(t) \in P = \{0, 1, 2, 3\}$  — рука, нога, сумка, туловище — положение телефона.

В подзадачах классификации и регрессии  $x$  разбивается на перекрывающиеся отрезки времени  $x_i$  длины *window*size (200) которые играют роль признаков, а  $v_i, p_i$  — класс и положение в конечный момент отрезка  $x_i$  — объектов.

## Подзадачи

- 1 Определить класс  $p$  — положения телефона — моделью  $f_1$ .
- 2 С помощью модели  $f_2(\cdot, p)$  найти скорости.
- 3 Скорость интегрируется для получения траектории

## Оценка качества модели

- 1 Точность предсказания класса
- 2 Сумма квадратов отклонений предсказанных скоростей от истинных

## Цель

Сравнить поведение различных моделей в каждой из подзадач. Подобрать оптимальные гиперпараметры.

## Данные

Данные взяты из <sup>a</sup>. Траектории сняты при 4 различных положениях телефона и с нескольких людей.

Также используются свои данные, снятые с другой модели телефона, но без истинной траектории.

---

<sup>a</sup>Hang Yan, Qi Shan, and Yasutaka Furukawa. Ridi: Robust imu double integration. CoRR, abs/1712.09004, 2017.

## Метод, используемый в базовом решении

- SVM-классификатор и SVM-регрессор с гауссовским ядром
- Использовалась предобученная модель.

## Метод ближайших соседей

- kNN-классификатор и kNN-регрессор
- Метрика —  $l_1$ , число соседей — 5, веса — расстояние.

## Свёрточные нейронные сети


- Классификация — 3 свёрточных слоя, 2 полносвязных
- Регрессия — 3 свёрточных слоя, 4 полносвязных



**Таблица:** Точность классификации и среднеквадратичная ошибка регрессии скорости на валидации

Модель	Точность	Ошибка	Размер, в мб	
			классификатор	регрессоры
SVM	0.379	0.085	30	130
kNN	0.372	0.027	260	260
CNN	0.381	0.013	0.006	0.2

Заметьте, что средняя скорость движения  $\sim 1.1$  м/с.



В отличие от остальных моделей на нашей выборке SVM показывает хороший результат.

## Выводы

- Все модели обладают невысокой точностью классификации, что скорее всего вызвано недостатком данных.
- Также несмотря на то, что среднеквадратичная ошибка регрессии у CNN и kNN ниже, качество восстановленной траектории значительно хуже, чем у SVM. Это означает, что она не подходит для сравнения моделей.

## Дальнейшее развитие

- Собрать больше данных для увеличения качества.
- Придумать способы генерации синтетических данных из существующих