

Определение местоположения по сигналам акселерометра*

Зайнулина Э. Т., Киселёва Е. А., Фатеев Д. А., Божedomов Н.,
Толканев А. А., Ночевкин В., Протасов В., Рябов А.

Аннотация: данная статья посвящена методам отслеживания местоположения человека по сигналам акселерометра, гироскопа, магнитометра. Основной задачей исследования является увеличение точности позиционирования в условиях, когда глобальная навигационная система не может быть использована. В качестве базовой модели был выбран PDR (pedestrian dead reckoning). Для уменьшения зашумленности данных был использован фильтр Калмана. Новизна исследования заключается в постановке задачи в терминах Projection to Latent Spaces.

Ключевые слова: *Pedestrian dead reckoning, (Indoor) inertial positioning, Simultaneous Localization and Mapping, PLS.*

1 Введение

В настоящее время системы по определению местоположения человека стали неотъемлемой частью повседневной жизни. Информация о точном местоположении человека используется для обеспечения безопасности, для “мобильного здоровья”, для эффективной организации рабочих процессов, для мониторинга толпы и др. Огромную роль в определении местоположения человека играет GNSS (глобальная навигационная система). Однако в помещении навигационные спутниковые сигналы не всегда доступны, из-за чего качество данных, предоставляемых GNSS, сильно уменьшается. Тем не менее большую часть времени человек проводит в помещениях, в связи с чем должны быть разработаны надежные, точные методы, позволяющие определять местоположение человека в помещении.

Современные смартфоны обладают большим числом сенсоров и высокой вычислительной способностью. Так как в настоящее время почти каждый человек им обладает, то методы определения местоположения человека с использованием смартфонов получили наибольшее внимание со стороны исследователей. Среди этих методов - методы, основанные на беспроводных сигналах (WiFi, Bluetooth, UWB) [12] [7], датчиках обзора (лазерный сканер, монокулярная и бинокулярная камера) [1], инерционных датчиках (акселерометр, гироскоп, магнитометр) [9] [4] [13] [6]. Многие из предложенных методов локализации человека представляют собой комбинацию выше перечисленных для увеличения точности позиционирования [3] [2] [8]. Методы, основанные на беспроводных сигналах и датчиках обзора, помимо наличия смартфона требуют также введения дополнительного оборудования либо наличия дополнительных знаний, например карты помещения или базы данных силы сигнала (RSSI) WiFi точки в зависимости от координаты (WiFi fingerprint). Однако не всегда возможно предоставить карту помещения, например, в силу конфиденциальности; вспомогательное оборудование, в свою очередь, требует технического обслуживания и больших затрат. Что касается WiFi позиционирования, то при наличии существующей базы данных WiFi fingerprint при некотором изменении среды, позиционирование будет неточным, поэтому база данных нуждается в постоянном обновлении [11].

Чтобы избежать данных проблем, предлагается метод, основанный на инерционных датчиках. В качестве базового алгоритма рассматривается pedestrian dead reckoning

* Научный руководитель: Стризов В.В. Консультант: Мотренко А.

(PDR) [5]. По сравнению с методами, основанными на беспроводных сигналах и датчиках обзора, PDR рассчитывает относительно точное местоположение человека быстрее и потребляя меньше вычислительной мощности. Для фильтрации шума в данных используется фильтр Калмана [14]. Особенность данной работы состоит в том, чтобы восстанавливать траекторию не от точки к точке, а всю целиком. Для работы с полученным многомерным пространством предлагается использовать метод PLS [10].

2 Постановка задачи

Данные, полученные с помощью инерционных датчиков, представляют собой многомерные временные ряды $s(t) \in \mathbb{R}^N$. Каждому временному ряду сопоставляется вектор признаков. Эти вектора образуют матрицу признаков $X \in \mathbb{R}^{N \times T}$. По матрице X необходимо предсказать траекторию пешехода $Y \in \mathbb{R}^{2 \times T}$, где строками матрицы Y являются временные ряды $y(t)$, описывающие изменения глобальных координат (широта и долгота соответственно) пешехода во времени. Искомая модель:

$$f : X \rightarrow Y$$

В силу зависимости получаемых данных от расположения смартфона данная задача разбивается на 2 подзадачи. Первая подзадача состоит в том, чтобы определить класс P расположения датчиков: нога, рука, сумка, тело ($\{0, 1, 2, 3\}$). Вторая подзадача состоит уже в предсказании траектории на основе полученного класса:

$$f \rightarrow f_1 f_2$$

$$f_1 : X \rightarrow P = \{0, 1, 2, 3\}$$

$$f_2 : X, P \rightarrow Y$$

Для решения данных задач используется метод опорных векторов, который минимизирует следующий функционал $S(w|f, X, Y)$:

$$\min_{w, w_0} S(w, w_0) = \|w\|^2 + C \sum_i \xi_i$$

$$\text{subject to } y_i(w^T x_i + w_0) \geq 1 - \xi_i \text{ and } \xi_i \geq 0 \forall i$$

Для оценки качества модели используется критерий суммы квадратов отклонений предсказанных координат от истинных, а также корреляция между предсказанной и истинной траекториями пешехода.

Формально постановку задачи можно записать следующим образом:

$$w^* = \arg \min_w S(w|f, X, Y).$$

3 Базовый алгоритм

Для получения матрицы признаков X предварительно из данных удаляются высокочастотные шумы с помощью сглаживания Гаусса. Полученные линейные и угловые скорости уже преобразуются в вектор признаков.

В качестве базового алгоритма используется каскадная регрессия, состоящая из SVM-классификатора и 8 SVR-регрессоров [14].

По матрице признаков X SVM-классификатор определяет, какому расположению датчиков (в руке, на ноге, на поясе, в сумке) соответствует данное описание, т.е. решает задачу многоклассовой классификации с 4 классами.

После этого для каждого класса на тренировочной выборке обучается свой SVR-регрессор, который выдает скорости движения пешехода для каждого временного блока. Полученные скорости содержат ошибку, связанную с неточностями инерционных датчиков, поэтому далее для этих скоростей находится смещение (по предположению низкочастотное) из следующей задачи минимизации:

$$\min_{\{x_I^1, x^5 1_I, \dots\}} V_{bias} = \min_{\{x_I^1, x^5 1_I, \dots\}} \sum_{f \in F_2} \|v_C^f - v_R^f\| + \lambda \sum_{f \in F_1} \|x_I^f\|^2,$$

$$v_C^f = R_{SW}^f \sum_{f'=1}^f R_{WI}^{f'} (a_I^{f'} + x_I^{f'}),$$

где f - единица блока выборки, F - блок выборки, v_C^f - скорректированное значение скорости, v_R^f - предсказанное значение скорости, I - система координат устройства, W - глобальная система координат, S - IMU-стабилизированная система координат, R_{AB} - матрица перехода из системы координат B в систему координат A .

Также для каждого класса создается SVR-регрессор, предсказывающий угловые скорости пешехода в каждом временном блоке.

На контрольной выборке для SVM-классификатора и каждого SVR-регрессора подбираются оптимальные значения гиперпараметров.

По полученным значениям скоростей восстанавливается траектория пешехода.

Формально алгоритм описывается следующим образом:

После получения из данных матрицы признаков X

Вход: $X, Y_{class}, Y, X_{test}$

- 1: $classifier = SVMClassifier(classifier_options);$
- 2: $classifier.fit(X, Y_{class})$
- 3: **для** cls in $classes$:
- 4: $regressor_cls = SVRRegressor(regressor_cls_options)$
- 5: $regressor_cls.fit(X[X[ind] \in cls], Y[Y[ind] \in cls])$
- 6: $Y_{test-class} = classifier.predict(X_{test})$
- 7: **для** cls in $classes$:
- 8: $Velocity_cls = regressor_cls.predict(X_{test}[Velocity_class[ind] == cls])$
- 9: $x_I^1, x^5 1_I, \dots = \arg \min_{\{x_I^1, x^5 1_I, \dots\}} V_{bias_cls}$
- 10: $Velocity_cls = R_{SW}^f \sum_{f'=1}^f R_{WI}^{f'} (a_I^{f'} + x_I^{f'})$
- 11: Trajectory_ cls recovery depending on Velocity_ cls
- 12: **return** Full_trajectory

4 Вычислительный эксперимент

Цель эксперимента: предсказать траекторию пешехода, близкую к истинной.

Для эксперимента используется часть данных, собранных в статье, описывающей алгоритм RIDI [14]. Эти данные были получены с помощью инерционных датчиков, расположенных в смартфонах в нескольких случаях: когда смартфон располагался на поясе, в руке, на ноге или в сумке. Выборки содержат различные траектории длиной в

100 минут и частотой сигнала 200 Гц. В качестве объекта рассматривается положение в определенный момент времени i . Признаками объекта являются угловые скорости и линейные ускорения в стабилизированной системе координат датчиков в моменты времени $i - window_size, \dots, i$, где $window_size$ - размер окна (равен 200). Целевыми переменными являются метки классов, характеризующие то, в каком положении находился смартфон при получении определенных данных, а также скорости в данный момент времени i , которые вычисляются через координаты пешехода и прошедшее время.

Литература

- [1] Erich Bruns and Oliver Bimber. Adaptive training of video sets for image recognition on mobile phones. *Personal and Ubiquitous Computing*, 13(2):165–178, 2009.
- [2] L. Chen, E. H. Wu, M. Jin, and G. Chen. Intelligent fusion of wi-fi and inertial sensor-based positioning systems for indoor pedestrian navigation. *IEEE Sensors Journal*, 14(11):4034–4042, Nov 2014.
- [3] Frédéric Evennou and François Marx. Advanced integration of wifi and inertial navigation systems for indoor mobile positioning. *EURASIP J. Adv. Sig. Proc.*, 2006, 2006.
- [4] Michael Hardegger, Daniel Roggen, and Gerhard Tröster. 3d actionslam: wearable person tracking in multi-floor environments. *Personal and Ubiquitous Computing*, 19(1):123–141, 2015.
- [5] R. Hostettler and S. Särkkä. Imu and magnetometer modeling for smartphone-based pdr. In *2016 International Conference on Indoor Positioning and Indoor Navigation (IPIN)*, pages 1–8, Oct 2016.
- [6] W. Kang and Y. Han. Smartpdr: Smartphone-based pedestrian dead reckoning for indoor localization. *IEEE Sensors Journal*, 15(5):2906–2916, May 2015.
- [7] Soo-Cheol Kim, Young-Sik Jeong, and Sang Oh Park. Rfid-based indoor location tracking to ensure the safety of the elderly in smart home environments. *Personal and Ubiquitous Computing*, 17(8):1699–1707, 2013.
- [8] M. Kok, J. D. Hol, and T. B. Schön. Indoor positioning using ultrawideband and inertial measurements. *IEEE Transactions on Vehicular Technology*, 64(4):1293–1303, April 2015.
- [9] Kwanghyo Park, Hyojeong Shin, and Hojung Cha. Smartphone-based pedestrian tracking in indoor corridor environments. *Personal and Ubiquitous Computing*, 17(2):359–370, 2013.
- [10] Roman Rosipal and Nicole Krämer. Overview and recent advances in partial least squares. In Craig Saunders, Marko Grobelnik, Steve Gunn, and John Shawe-Taylor, editors, *Subspace, Latent Structure and Feature Selection*, pages 34–51, Berlin, Heidelberg, 2006. Springer Berlin Heidelberg.
- [11] Joaquín Torres-Sospedra and Adriano J. C. Moreira. Analysis of sources of large positioning errors in deterministic fingerprinting. *Sensors*, 17(12):2736, 2017.
- [12] Rodrigo Vera, Sergio F. Ochoa, and Roberto G. Aldunate. Edips: an easy to deploy indoor positioning system to support loosely coupled mobile work. *Personal and Ubiquitous Computing*, 15(4):365–376, 2011.
- [13] Boyuan Wang, Xuelin Liu, Baoguo Yu, Ruicai Jia, and Xingli Gan. Pedestrian dead reckoning based on motion mode recognition using a smartphone. *Sensors*, 18(6):1811, 2018.
- [14] Hang Yan, Qi Shan, and Yasutaka Furukawa. Ridi: Robust imu double integration. *CoRR*, abs/1712.09004, 2017.